

# Appunti di machine learning

Daniele Besozzi

Anno accademico 2025/2026

# Contents

<b>1</b>	<b>Introduzione</b>	<b>2</b>
1.1	Vettori e matrici . . . . .	2
1.2	Norme di vettori e matrici . . . . .	2
1.3	Notazioni generiche . . . . .	3

# Premesse

Questi sono appunti realizzati per riassumere e schematizzare tutti i concetti presentati durante il corso di machine learning tenuto presso il corso di laurea magistrale in informatica presso l'università degli studi di Milano Bicocca. Lo scopo di questo documento non è quello di sostituire le lezioni del corso o di essere l'unica fonte di studio, bensì integrare le altri fonti con un documento riassuntivo.

Mi scuso in anticipo per eventuali errori e prego i lettori di segnalarli contattandomi via mail all'indirizzo [d.besozzi@campus.unimib.it](mailto:d.besozzi@campus.unimib.it).

# Chapter 1

## Introduzione

In questo capitolo presenterò gli aspetti matematici fondamentali per andare ad affrontare gli argomenti del corso.

### 1.1 Vettori e matrici

Denotiamo un vettore riga e colonna rispettivamente con  $(a, b, c)$  e  $\begin{bmatrix} a \\ b \\ c \end{bmatrix}$

dove  $a, b, c \in \mathbb{R}$  sono scalari.

In generale denotiamo con le lettere maiuscole le matrici, e.g.  $X$  e i suoi elementi con  $X_{ij}$ .

$x \in \mathbb{R}^n$  è un vettore di  $n$  elementi e  $X \in \mathbb{R}^{m \times n}$  è una matrice di dimensione  $m \times n$ .

### 1.2 Norme di vettori e matrici

Dato un vettore  $x \in \mathbb{R}^n$  vi sono diversi tipi di norme comunemente utilizzate.

- $\|x\|_2 = (\sum_{i=1}^n x_i^2)^{\frac{1}{2}}$  è il tipo più comune e viene chiamato **norma 2** di un vettore o **norma Euclidea**. Normalmente è denotato semplicemente con  $\|x\|$ .
- $\|x\|_1 = |x_1| + |x_2| + \dots + |x_n|$ , detta la **norma 1** o **distanza di Manhattan**
- $\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|$ , detta la **norma  $\infty$** .

Analogamente, per una matrice  $X \in \mathbb{R}^{m \times n}$ , si possono definire diverse norme:

- **Norma di Frobenius**:  $\|X\|_F = \left( \sum_{i=1}^m \sum_{j=1}^n |X_{ij}|^2 \right)^{\frac{1}{2}}$
- **Norma spettrale (o norma 2)**:  $\|X\|_2$
- **Norma 1**:  $\|X\|_1 = \sum_{i,j} |X_{ij}|$

## 1.3 Notazioni generiche

Siano:

- $u$ : variabile indipendente (input), non necessariamente un vettore o uno scalare
- $v$ : variabile dipendente (output), come sopra

allora abbiamo che:

- $x = \Phi(u)$ , dove  $x \in \mathbb{R}^d$  è il vettore di features e  $\Phi$  è la funzione di mapping o embedding.
- $y = \Psi(v)$ , dove  $y \in \mathbb{R}^m$  è il vettore target (o di output) e  $\Psi$  è la funzione di mapping di feature in output.

Siano  $x^1, \dots, x^n$  e  $y^1, \dots, y^n$  due dataset di  $n$  esempi, dove  $x^i$  e  $y^i$  formano la  $i$ -esima coppia di dati. Dunque  $n$  è il numero di campioni, allora posso associarvi le due matrici dei dati

$$X = \begin{bmatrix} (x^1)^T \\ \vdots \\ (x^n)^T \end{bmatrix} \in \mathbb{R}^{n \times d}, \quad Y = \begin{bmatrix} (y^1)^T \\ \vdots \\ (y^n)^T \end{bmatrix} \in \mathbb{R}^{n \times m}$$

Le cui righe sono i vettori feature e i vettori target rispettivamente, trasposti.

Definiamo allora:

- $g_\theta : \mathbb{R}^d \rightarrow \mathbb{R}^m$  è un predittore.
- $\hat{y} = g_\theta(x)$  è la predizione di  $y$ , dato  $x$ .
- $\Theta \in \mathbb{R}^p$  è il vettore di parametri del predittore.

La scelta dei parametri  $\Theta$  a seconda dei dati viene chiamato *training* o *fitting* del predittore.